Documentação: Aplicação de Scraping para Análise de Perfis Públicos no Instagram

---

1. Introdução

Esta aplicação será desenvolvida para realizar o scraping de perfis públicos no Instagram com o objetivo de identificar contas elegíveis ao público-alvo do time de vendas. A análise será baseada em palavras-chave fornecidas pelo usuário, verificando se essas palavras estão presentes no nome do perfil, bio, link da bio, hashtags e legendas dos posts. Perfis identificados como elegíveis serão armazenados no banco de dados.

---

2. Objetivos

2.1 Objetivo Principal

Identificar perfis públicos no Instagram que correspondam a critérios estabelecidos, com base em palavras-chave, e armazenar os dados em um banco de dados.

2.2 Objetivos Secundários

1. Realizar a análise de perfis de forma automatizada e eficiente.
2. Garantir a flexibilidade para configurar intervalos de execução e volume de requisições no frontend.
3. Armazenar dados de perfis elegíveis no banco de dados.
4. Criar logs de execução para auditoria e análise de desempenho.

---

3. Requisitos

3.1 Funcionais

1. **Busca Avançada por Palavras-Chave**:
    - Verificar palavras-chave no:
        - Nome do perfil.
        - Bio.
        - Link na bio.
        - Hashtags.
        - Url do perfil.
        - Legendas dos posts.
2. **Análise de Perfis**:
    - Avaliar todas as postagens de um perfil público.

    - Decidir se o perfil é elegível com base na busca por palavras-chave.
3. **Gestão de Dados no Banco**:
    - **Perfis elegíveis**:
        - Inserir novos perfis na tabela `perfis`.
        - Atualizar perfis existentes.
        - Armazenar histórico de atualizações.
4. **Configuração de Automação**:
    - Configuração no frontend para:
        - Intervalo de execução em horas.
        - Quantidade máxima de requisições por hora ou dia.
5. **Logs de Execução**:
    - Registrar dados detalhados de cada execução:
        - Total perfis elegíveis inseridos ou atualizados.

3.2 Não Funcionais

1. **Conformidade com Políticas**:
    - Limitar o scraping a dados públicos e evitar excesso de requisições.
2. **Interface Interativa**:
    - Painel frontend com design responsivo.
3. **Escalabilidade**:
    - Suporte a grandes volumes de dados.
4. **Desempenho**:
    - Processamento eficiente dos dados coletados.

---

4. Estrutura de Armazenamento no Banco de Dados

4.1 Tabela de Perfis

- **Tabela: `perfis`**
    - `id` (chave primária, único para cada perfil).
    - `username` (nome do perfil).
    - `bio` (descrição do perfil).
    - `link_bio` (URL presente na bio).
    - `url_perfil` (URL do perfil).
    - `hashtags_usadas` (hashtags mais frequentes no perfil).
    - `ultima_publicacao` (data da última postagem).
    - `frequencia_publicacao` (média de intervalo entre postagens).
    - `imagem_post` (URL da imagem do último post).
    - `legenda_post` (legenda associada à imagem armazenada).
    - `ultima_atualizacao` (**datetime**: ano, mês, dia, hora, minuto, segundo, milissegundo).
    - `novo` (valida se o perfil encontrado é novo ou não).

4.2 Tabela de Histórico de Atualizações

- **Tabela:** `historico_atualizacoes`
  - `id` (chave primária).
  - `id_cliente` (foreign key de `perfils`).
  - `username` (nome do perfil).
  - `bio` (descrição do perfil).
  - `link_bio` (URL presente na bio).
  - `url_perfil` (URL do perfil).
  - `hashtags_usadas` (hashtags mais frequentes no perfil).
  - `ultima_publicacao` (data da última postagem).
  - `frequencia_publicacao` (média de intervalo entre postagens em horas).
  - `imagem_post` (URL da imagem do último post).
  - `legenda_post` (legenda associada à imagem armazenada).
  - `ultima_atualizacao` (**datetime**: ano, mês, dia, hora, minuto, segundo, milissegundo).

4.3 Logs de Execuções

- **Tabela:** `logs_execucoes`
  - `id` (chave primária).
  - `hora_inicio` (**datetime**: início da automação).
  - `hora_fim` (**datetime**: término da automação).
  - `total_perfis_analisados` (quantidade total de perfis processados).
  - `novos_perfis` (quantidade de perfis novos inseridos).
  - `perfis_atualizados` (quantidade de perfis atualizados).

---

5. Fluxo de Trabalho

5.1 Automação

1. **Configuração no Frontend**:
   - Intervalo de execução (horas e limites por hora/dia).
2. **Busca por Palavras-Chave**:
   - Verificar correspondência em todos os dados públicos do perfil (nome, bio, hashtags, legendas, links).
3. **Avaliação e Armazenamento**:
   - Perfis elegíveis:
     - **Novo perfil**: Inserir dados na tabela `perfis`.
     - **Perfil existente**: Atualizar dados e registrar histórico na tabela `historico_atualizacoes`.
4. **Logs de Execução**:
   - Registrar informações detalhadas sobre a execução no banco.

---

6. Ferramentas e Tecnologias

6.1 Tecnologias

- **Backend**:
  - Linguagem: Python.
  - Frameworks: Flask.
- **Banco de Dados**:
  - MySQL.
- **Frontend**:
  - HTML/CSS, React.js ou Vue.js.
- **Automação**:
  - Celery ou APScheduler.

6.2 Bibliotecas

- **Scraping**:
  - Selenium ou Playwright.
  - BeautifulSoup.
- **Banco de Dados**:
  - SQLAlchemy.
- **Agendamento**:
  - Celery, APScheduler.
- **Frontend**:
  - Axios (requisições HTTP).
- **Visualização**
  - Plotly ou Matplotlib.

---

7. Configuração do Frontend

7.1 Ferramentas

- **HTML/CSS**: Estrutura básica e design responsivo.
- **React.js** ou **Vue.js**: Para interatividade e configuração do painel.

7.2 Funcionalidades do Painel

1. **Configuração da Automação**:
   - Intervalo em horas.
   - Limite máximo de requisições por hora/dia.
2. **Busca por Palavras-Chave**:
   - Entrada para palavras-chave.
   - Botão de execução manual.
3. **Exibição de Logs**:
   - Histórico detalhado de execuções.
   - Perfis encontrados e atualizados.

---

8. Riscos e Mitigações

8.1 Riscos

1. **Bloqueio de IP**:
    - Excesso de requisições pode resultar em penalizações.
2. **Inconsistência de Dados**:
    - Alterações nos perfis durante a coleta.

8.2 Mitigações

1. **Uso de Proxies**:
    - Distribuir requisições para evitar bloqueios.
2. **Validação e Logs**:
    - Monitorar e corrigir inconsistências através dos logs.

---

9. Análise de Viabilidade para Captura de Imagens

A captura de imagens através do scraping é tecnicamente possível, desde que sejam respeitadas as políticas de uso do Instagram. Para imagens de posts, o scraping pode obter:

- URLs diretas de imagens públicas ou realizar o download da imagem e armazenar no banco (vamos trabalhar com a primeira opção).

---

10. Resultados Esperados

1. Coleta e análise eficiente de perfis públicos do Instagram.
2. Armazenamento detalhado de dados.
3. Configuração flexível de intervalos no painel interativo.
4. Logs completos e histórico de atualizações para auditoria.